

INFORME DE FACTIBILIDAD ÉTICA, FINANCIERA Y DE RIESGOS

Caso 2 — Salud: Costos Médicos y Bienestar del Paciente

Asignatura: SCY1102 – Gestión de Proyectos de Datos | Evaluación Parcial N°1 (Encargo)

Integrantes: Diego Medina · Ignacio Arriagada · Javier Tapia · Pedro Ponce

Duoc UC – Ingeniería en Ciencia de Datos | 2026

Este informe se acompaña de un anexo técnico reproducible (Anexo_Analisis_Caso2.ipynb) que respalda con código Python (pandas, statsmodels) cada cifra citada en las secciones 2 a 5. La sección 6 describe cómo ejecutarlo.

1. Contexto del proyecto

Una aseguradora de salud privada requiere analizar los factores que explican los costos anuales de atención médica de sus afiliados con el fin de estimar presupuestos, mejorar la planificación operativa y diseñar programas preventivos costo-efectivos. Para ello dispone de un dataset histórico de 1.338 afiliados con siete variables: edad, sexo, índice de masa corporal (IMC), número de hijos, condición de tabaquismo, región de residencia y monto anual de gasto médico (charges). El presente informe evalúa la factibilidad ética, financiera y de riesgos de implementar un modelo de regresión predictiva sobre estos datos, considerando su uso posterior en planificación agregada, focalización de programas preventivos y presupuestación de la compañía.

Hallazgos preliminares del análisis exploratorio (respaldo: notebook §3, §4 y §7): la variable con mayor impacto es el tabaquismo — los fumadores presentan un costo promedio de US\$ 32.050 frente a US\$ 8.434 de los no fumadores (3,80× más). La interacción tabaquismo × obesidad eleva el costo promedio a US\$ 41.693 (4,71× el gasto de un no fumador obeso). Un modelo de regresión OLS con statsmodels (ver notebook §7) confirma que ser fumador aporta +US\$ 23.848 al costo anual esperado con $p < 0,001$ y un R^2 ajustado de 0,749, mientras que la edad aporta +US\$ 257 por año y cada punto de IMC +US\$ 339. El dataset no contiene valores nulos y presenta una única fila duplicada (0,07 % de los registros), sin efecto material sobre los resultados.

2. Análisis ético

2.1 Identificación de sesgos en los datos

- Sesgo geográfico y cultural: el dataset proviene de EE.UU. (regiones northeast, northwest, southeast, southwest) y no representa la estructura demográfica ni el sistema de salud chileno; trasladar sus coeficientes a la aseguradora local sin recalibración induciría error sistemático (notebook §5).
- Sesgo de representación en tabaquismo: solo el 20,5 % de la muestra fuma (274 de 1.338), lo que reduce la precisión con que el modelo estima el comportamiento de ese subgrupo —cuya dispersión de charges casi duplica la de los no fumadores— y degrada su desempeño sobre casos extremos (notebook §5).
- Sesgo por subrepresentación en IMC bajo: apenas 20 personas presentan $IMC < 18,5$ (1,5 % de la muestra). Cualquier predicción sobre bajo peso será estadísticamente débil y podría penalizar injustamente a personas con condiciones asociadas — trastornos alimentarios, enfermedades crónicas (notebook §5).
- Sesgo de género binario: la variable sex solo contempla "male/female", excluyendo personas no binarias o trans y reforzando una categorización que puede resultar discriminatoria.
- Sesgo por variables omitidas: no existen datos socioeconómicos (ingreso, educación, ocupación) ni de acceso al sistema de salud. La región puede actuar como proxy de nivel socioeconómico e introducir discriminación indirecta — southeast concentra la mayor tasa de fumadores (25,0 %) y el mayor costo promedio (US\$ 14.735).

- Sesgo histórico: los costos observados reflejan patrones pasados de discriminación en aseguradoras (cobros más altos a mujeres o a residentes de zonas específicas), que un modelo podría perpetuar si se entrena sin controles de equidad.

2.2 Impactos éticos potenciales

Un modelo entrenado sobre este dataset y usado para tarificar primas podría (i) discriminar indirectamente a personas obesas o fumadoras encareciendo su acceso al seguro, en lugar de orientarlas a programas preventivos; (ii) profundizar brechas territoriales al cobrar más a regiones asociadas con menor nivel socioeconómico; (iii) vulnerar la Ley N° 19.628 sobre protección de datos personales y la Ley N° 21.719 (2024) que refuerza los estándares de datos sensibles, entre los que se encuentran los de salud; y (iv) generar un impacto reputacional grave ante organismos como la Superintendencia de Salud y organizaciones de defensa de pacientes. El coeficiente del modelo OLS (+US\$ 23.848 por ser fumador) confirma que existe un incentivo económico directo para discriminar si no se restringe el uso del modelo.

2.3 Medidas de mitigación

- Recalibración con datos locales: incorporar al menos una muestra representativa chilena (Encuesta CASEN, ENS 2016-2017, base de FONASA/Isapres) antes de desplegar el modelo.
- Auditoría de equidad (fairness audit): calcular métricas de disparate impact y equal opportunity por sexo, región e IMC; documentar y publicar los resultados en la ficha del modelo (model card), siguiendo las prácticas de auditoría descritas por Barocas et al. (2023). El notebook \$5 entrega la base cuantitativa para monitorear cada uno de estos ejes.
- Restricciones de uso: prohibir el uso del modelo para negar cobertura o subir primas individuales; limitarlo a planificación agregada y focalización de programas preventivos.
- Anonimización y minimización: aplicar k-anonymity ($k \geq 5$), eliminar identificadores directos y cifrar en reposo y en tránsito (AES-256, TLS 1.3).
- Gobernanza: comité de ética que revise trimestralmente el desempeño y los sesgos, con representación clínica, jurídica y de pacientes.
- Transparencia: publicar un aviso explicativo simple para afiliados, incluir SHAP como método de explicabilidad y ofrecer canal de apelación humano frente a decisiones automatizadas.

3. Evaluación financiera

Se comparan dos alternativas de arquitectura para desarrollar y operar el modelo durante un año, considerando cuatro rubros: infraestructura cloud, licencias de software, recursos humanos y servicios/agentes automáticos. Los valores están expresados en dólares estadounidenses (US\$) y se basan en las calculadoras oficiales de AWS y Microsoft Azure, y en referencias salariales de Trabajando.com y Michael Page Chile 2025.

3.1 Estimación de costos por rubro

Rubro	Alt. A — AWS + Python open source (US\$/año)	Alt. B — Azure ML + Power BI Premium (US\$/año)
Infraestructura cloud	EC2 t3.medium + S3 + RDS PostgreSQL: US\$ 8.400	Azure ML compute + Blob Storage + SQL DB: US\$ 14.400
Licencias de software	Python, scikit-learn, MLflow, Metabase: US\$ 0 (open source)	Azure ML Studio + Power BI Premium (2 usr): US\$ 12.000
Recursos humanos	1 data scientist jr (½ jornada) + 1 data engineer (¼ j.): US\$ 42.000	1 data scientist + 1 arquitecto Azure (½ j.): US\$ 48.000
Servicios / agentes automáticos	API Gateway + Lambda re-entrenamiento mensual: US\$	Azure Functions + Logic Apps + monitoreo: US\$ 6.000

	3.600	
Total anual	US\$ 54.000	US\$ 80.400

3.2 Comparación costo-beneficio

La Alternativa A (AWS + Python open source) presenta un costo anual 33 % menor (US\$ 54.000 vs US\$ 80.400), con la desventaja de requerir mayor esfuerzo interno de configuración y monitoreo. La Alternativa B (Azure ML + Power BI Premium) reduce el time-to-market gracias a herramientas gestionadas y ofrece integración directa con dashboards ejecutivos, pero encarece el modelo un 49 % adicional y genera dependencia (vendor lock-in) con Microsoft.

El beneficio esperado del proyecto se cuantifica en el notebook §8: el subgrupo fumador-obeso representa el 10,76 % del padrón (144 de 1.338 afiliados) pero concentra el 33,81 % del gasto anual total, una concentración de 3,1×. Sobre esa base se modela el ahorro que produciría un programa preventivo de cesación de tabaco y control del peso. Como la magnitud de ese efecto no se deriva de los datos sino de un supuesto, se evalúan tres escenarios (notebook §8.1):

Reducción del gasto del subgrupo	Ahorro anual (US\$)	ROI Alt. A	ROI Alt. B
5 % — escenario pesimista	300.188	5,6×	3,7×
10 % — escenario base	600.376	11,1×	7,5×
20 % — escenario optimista	1.200.753	22,2×	14,9×

Se adopta el escenario base del 10 % por ser el más defendible: los programas de cesación de tabaco y control de peso muestran efectos reales pero moderados, y el ahorro clínico se materializa de forma gradual. Aun en el escenario pesimista la Alternativa A conserva un ROI de 5,6×, y supera a la Alternativa B en los tres escenarios. La brecha justifica priorizar la opción de menor costo y mayor flexibilidad tecnológica.

Alcance del cálculo. Estas cifras se estiman sobre la cohorte analizada de 1.338 afiliados y no constituyen una proyección del padrón completo de la aseguradora. Al escalar a un padrón mayor el gasto crece de forma aproximadamente proporcional mientras el costo del proyecto analítico permanece casi fijo, por lo que el ROI aumentaría en lugar de deteriorarse; reescalar el análisis al mercado chileno exige recalibrar con estadísticas locales de gasto en salud (Superintendencia de Salud, 2024). Debe notarse además que el ROI compara el ahorro contra el costo del proyecto analítico, no contra el del programa preventivo que lo genera: el retorno es alto precisamente porque la analítica resulta marginal frente a la masa de gasto, de modo que el caso de negocio definitivo depende del costo de la intervención clínica, fuera del alcance de este informe.

3.3 Alternativa seleccionada

Se recomienda la Alternativa A (AWS + stack open source). Se justifica por: (i) menor costo total y mejor ROI, (ii) portabilidad — el código Python del anexo técnico puede migrarse a otro proveedor sin reescritura, (iii) mayor control sobre las auditorías de sesgo (código abierto, reproducible) exigidas por la sección 2.3, y (iv) trayectoria interna del equipo en Python. Se sugiere reservar US\$ 6.000 anuales adicionales para contratar horas de un consultor DevOps que acompañe la implementación durante los primeros seis meses.

4. Análisis de riesgos

4.1 Matriz de riesgos

Escala: Probabilidad (1 muy baja – 5 muy alta) × Impacto (1 muy bajo – 5 muy alto). Nivel = $P \times I$. Verde ≤ 6, Amarillo 7–14, Rojo ≥ 15.

ID	Tipo	Descripción	P	I	Nivel	Estrategia de mitigación
R1	Ético	Discriminación por IMC, sexo o región al usar el modelo para tarificar primas	4	5	20	Restringir el uso del modelo a planificación agregada; auditoría de fairness trimestral; revisión por comité de ética.
R2	Legal	Filtración o uso no autorizado de datos de salud (Ley 19.628 y Ley 21.719)	3	5	15	Cifrado AES-256 en reposo y TLS 1.3 en tránsito; k-anonymity ($k \geq 5$); DPO designado; contrato de encargado con AWS.
R3	Técnico	Sesgo del modelo por sub-representación (IMC bajo, no binarios, chilenos)	4	4	16	Recalibrar con datos locales (CASEN, ENS, FONASA); reweighting durante entrenamiento; métricas segmentadas.
R4	Técnico	Deriva del modelo (data drift) por cambios epidemiológicos o post-pandemia	2	4	8	Monitoreo continuo de PSI y KS; re-entrenamiento programado cada 6 meses; alertas automáticas.
R5	Financiero	Sobrecosto de infraestructura cloud por consumo no controlado	3	4	12	Presupuesto AWS con alertas al 70 %/90 %; uso de instancias reservadas 1 año; revisión mensual de FinOps.
R6	Legal	Sanción de la Superintendencia por decisiones automatizadas sin explicación	2	5	10	Explainability (SHAP) obligatorio; canal humano de apelación; registro de

						decisiones por 5 años.
R7	Técnico	Fallo de integración con sistemas legacy de la aseguradora	1	3	3	Pruebas de integración desde sprint 1; contrato de servicio con el equipo TI interno.
R8	Financiero	Rotación del data scientist principal	3	3	9	Documentación viva en Confluence; pair programming; retención salarial y bonos de proyecto.

4.2 Estrategias transversales de mitigación

- Adoptar el marco NIST AI Risk Management Framework (2023) como estándar de gestión.
- Certificar la aseguradora bajo ISO/IEC 27001 (seguridad) e ISO/IEC 42001 (gestión IA).
- Contratar póliza de ciberseguridad que cubra brecha de datos por al menos US\$ 500.000.
- Formalizar un plan de continuidad operacional del modelo con RTO $\leq$ 4 h y RPO $\leq$ 24 h.

5. Conclusión y recomendación final

El proyecto es viable siempre que se implemente con salvaguardas éticas y legales robustas. La evidencia estadística generada en el anexo técnico confirma que (i) el modelo OLS explica el 75 % de la varianza en charges (R^2 adj = 0,749), (ii) el efecto dominante es ser fumador (+US\$ 23.848 anuales, $p < 0,001$), y (iii) el subgrupo fumador-obeso (10,8 % del padrón) concentra el 33,8 % del gasto agregado, ofreciendo una oportunidad clara de ahorro por prevención focalizada con un ROI de 11,1× en el escenario base sobre la cohorte analizada. Se recomienda avanzar con la Alternativa A (AWS + open source, US\$ 54.000/año) bajo un piloto controlado de 6 meses en el que el modelo solo alimente reportes agregados para el área de programas preventivos, no decisiones individuales de precio. Al término del piloto, un comité independiente evaluará su expansión con base en métricas de equidad, ROI real y cumplimiento normativo, con especial énfasis en la Ley 19.628 y su reforma Ley 21.719.

6. Anexo técnico — Notebook Jupyter reproducible

Todas las cifras cuantitativas de este informe están respaldadas en el archivo Anexo_Analisis_Caso2.ipynb, que puede ejecutarse con Python 3.12 y las librerías pandas, numpy, matplotlib, seaborn y statsmodels. El notebook está organizado en 9 secciones que reproducen el flujo del informe:

Sección del notebook	Cifra o hallazgo que respalda
§1 Carga y calidad	1.338 filas, 7 columnas, 0 nulos, 1 duplicado
§2 Distribuciones	Composición del dataset (sexo, región, tabaquismo, edad, IMC)
§3 Costos por grupo	Fumadores 3,80× más; southeast US\$ 14.735 promedio
§4 Interacción tabaquismo × IMC	Fumador+obeso = US\$ 41.693 (4,71× no fumador obeso)
§5 Sesgos cuantificados	20 casos IMC bajo (1,5 %); 274 fumadores (20,5 %)
§6 Correlaciones	age $r=0,299$; bmi $r=0,198$; children $r=0,068$
§7 Regresión OLS (statsmodels)	R^2 adj = 0,749; smoker +US\$ 23.848 ($p < 0,001$)

§8 Subgrupo crítico y sensibilidad	10,76 % de afiliados generan 33,81 % del gasto; ROI base 11,1× (\$8.1)
§9 Conclusiones	Validación final cruzada con cada afirmación del informe

Reproducibilidad: colocar insurance.csv en la misma carpeta que el notebook y ejecutar "Kernel → Restart & Run All" en Jupyter Lab, VS Code o Google Colab. Tiempo de ejecución estimado: menos de 10 segundos.

Referencias (APA 7)

- Amazon Web Services. (2025). AWS Pricing Calculator. <https://calculator.aws>
- Barocas, S., Hardt, M., & Narayanan, A. (2023). Fairness and machine learning. MIT Press.
- Biblioteca del Congreso Nacional de Chile. (1999). Ley N° 19.628 sobre protección de la vida privada. <https://www.bcn.cl/leychile/navegar?idNorma=141599>
- Biblioteca del Congreso Nacional de Chile. (2024). Ley N° 21.719 que regula la protección y el tratamiento de los datos personales. <https://www.bcn.cl/leychile>
- ISO/IEC. (2023). ISO/IEC 42001:2023 — Information technology — Artificial intelligence — Management system.
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions (SHAP). Advances in Neural Information Processing Systems, 30.
- Microsoft. (2025). Azure pricing calculator. <https://azure.microsoft.com/pricing/calculator/>
- Ministerio de Salud de Chile. (2017). Encuesta Nacional de Salud 2016-2017. MINSAL.
- National Institute of Standards and Technology. (2023). AI Risk Management Framework (AI RMF 1.0). <https://doi.org/10.6028/NIST.AI.100-1>
- Seabold, S., & Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. Proceedings of the 9th Python in Science Conference.
- Superintendencia de Salud. (2024). Boletín estadístico de Isapres 2023. <https://www.supersalud.gob.cl>
- Trabajando.com Chile. (2025). Estudio de remuneraciones — Tecnología y Datos.