

Factibilidad ética, financiera y de riesgos

Caso 2 — Salud: Costos Médicos y Bienestar del Paciente

Evaluación Parcial N°2 · Presentación grupal

Con evidencia respaldada en Jupyter Notebook (Anexo técnico)

Integrantes: Diego Medina · Ignacio Arriagada · Javier Tapia · Pedro Ponce · 2026

Aseguradora de salud privada · dataset 1.338 afiliados

Objetivo

Estimar costos médicos anuales para planificar presupuestos y focalizar programas preventivos.

Dataset


1.338 registros · 7 variables · 0 nulos · 1 duplicado
Edad, sexo, IMC, hijos, tabaquismo, región, charges

Uso previsto

Reportes agregados y focalización de prevención — NO tarificación individual automatizada.

Evidencia notebook \$1

Efecto multiplicativo, no aditivo: 4,71× vs un no fumador obeso (notebook \$4)



Cifras clave

3,8×

gastan los fumadores

US\$ 41.693

promedio fumador+obeso

US\$ 8.853

promedio no fumador obeso

20,5 %

afiliados son fumadores

33,8 %

del gasto lo genera el 10,8 % de afiliados

Evidencia notebook \$4

Cuantificados con Notebook \$5

Geográfico

Datos de EE.UU. — no representa Chile.

Tabaquismo

Solo 20,5 % fumadores (274/1338).

IMC bajo

Solo 20 casos (1,5 %) → no confiable.

Género binario

Excluye personas no binarias/trans.

Variables omitidas

Sin ingreso/educación. Región = proxy.

Histórico

Reproduce discriminación previa.

Evidencia notebook \$5

Notebook §5 — todos los números son reproducibles

In [9]:

```
# Sesgos cuantificados en el dataset
n_bajo = (df.bmi < 18.5).sum()
n_fum = (df.smoker == 'yes').sum()

print(f'IMC bajo: {n_bajo} ({n_bajo/len(df)*100:.1f}%)')
print(f'Fumadores: {n_fum} ({n_fum/len(df)*100:.1f}%)')
print(f'Categorías de sexo: {list(df.sex.unique())}')
print(f'Regiones (todas de EE.UU.): {list(df.region.unique())}')

# Fumadores por region
tasa = df.groupby('region').smoker.apply(lambda s: (s=='yes').mean()*100)
print('\n% de fumadores por region:')
print(tasa.round(1).to_string())
```

Out[]:

```
IMC bajo: 20 (1.5%)
Fumadores: 274 (20.5%)
Categorías de sexo: ['female', 'male']
Regiones (todas de EE.UU.): ['southwest', 'southeast', 'northwest', 'northeast']

% de fumadores por region:
region
northeast    20.7
northwest    17.8
southeast    25.0
southwest    17.8

>>> Sub-representacion IMC bajo (1.6%) y desbalance regional confirmados <<<
```

Hallazgos

- IMC bajo: 20 casos (1,5 %)
- Fumadores: 274 (20,5 %)
- Solo 2 categorías de sexo
- Southeast lidera fumadores
- Regiones EE.UU. exclusivas

Notebook \$7 — statsmodels valida el peso de cada variable

```
In [13]:
from statsmodels.formula.api import ols
modelo = ols('charges ~ age + bmi + children + C(sex) + C(smoker) + C(region)',
             data=df).fit()
print(modelo.summary())
```

Out[]:

OLS Regression Results						
=====						
Dep. Variable:	charges	R-squared:	0.751			
Model:	OLS	Adj. R-squared:	0.749			
Method:	Least Squares	F-statistic:	500.8			
Date:	Wed, 02 Sep 2026	Prob (F-statistic):	0.00			
Time:	00:35:42	Log-Likelihood:	-13548.			
No. Observations:	1338	AIC:	2.711e+04			
Df Residuals:	1329	BIC:	2.716e+04			
Df Model:	8					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

Intercept	-1.194e+04	987.819	-12.086	0.000	-1.39e+04	-1e+04
C(sex)[T.male]	-131.3144	332.945	-0.394	0.693	-784.470	521.842
C(smoker)[T.yes]	2.385e+04	413.153	57.723	0.000	2.3e+04	2.47e+04
C(region)[T.northwest]	-352.9639	476.276	-0.741	0.459	-1287.298	581.370
C(region)[T.southeast]	-1035.0220	478.692	-2.162	0.031	-1974.097	-95.947
C(region)[T.southwest]	-960.0510	477.933	-2.009	0.045	-1897.636	-22.466
age	256.8564	11.899	21.587	0.000	233.514	280.199
bmi	339.1935	28.599	11.860	0.000	283.088	395.298
children	475.5005	137.804	3.451	0.001	205.163	745.838
=====						
Omnibus:	300.366	Durbin-Watson:	2.088			
...						

Lectura clave

R² adj

0,749

Efecto FUMADOR

+US\$ 23.848 anuales

p-valor smoker

< 0,001 ***


Efecto edad

+US\$ 257 por año

Efecto IMC

+US\$ 339 por punto

Costos anuales estimados en US\$



Resumen

Alternativa A

AWS + Python OSS

US\$ 54.000

ROI $\approx 11,1\times$

Alternativa B

Azure ML + Power BI

US\$ 80.400

ROI $\approx 7,5\times$

✓ Recomendada: A

Notebook §8.1 — sensibilidad del ROI a tres escenarios

In [19]:

```
# Sensibilidad del ROI a la tasa de reduccion de gasto supuesta
COSTO_ALT_A, COSTO_ALT_B = 54_000, 80_400

filas = []
for red in (0.05, 0.10, 0.20):
    ahorro = gasto_crit * red
    filas.append({
        'Reduccion supuesta': f'{red:.0%}',
        'Ahorro anual (US$)': round(ahorro),
        'ROI Alt. A': round(ahorro / COSTO_ALT_A, 1),
        'ROI Alt. B': round(ahorro / COSTO_ALT_B, 1),
    })

sens = pd.DataFrame(filas).set_index('Reduccion supuesta')
print(sens.to_string())
```

Out[]:

SENSIBILIDAD DEL ROI (cohorte de 1.338 afiliados)

	Ahorro anual (US\$)	ROI Alt. A	ROI Alt. B
Reduccion supuesta			
5%	300188	5.6	3.7
10%	600376	11.1	7.5
20%	1200753	22.2	14.9

```
>>> ESCENARIO BASE (10 %): ahorro US$ 600,376
      | ROI Alt. A 11.1x | ROI Alt. B 7.5x <<<
```

Simulación

Escenario base: reducción del 10 % del gasto del subgrupo. Se evalúan también 5 % y 20 %.

Ahorro


US\$ 600.376

ROI vs Alt. A

11,1×

Aun en el escenario pesimista (5 %) la Alt. A rinde 5,6×. El ROI mide el proyecto analítico, no el programa clínico.

Probabilidad × Impacto — 8 riesgos identificados



Riesgos + mitigación

- R1** Discriminación IMC/sexo/región → auditoría fairness
- R2** Fuga datos salud → AES-256, k-anonymity, DPO
- R3** Sesgo sub-representación → recalibrar con datos CL
- R4** Data drift → monitoreo PSI y re-entrenamiento 6m
- R5** Sobrecosto cloud → alertas 70/90 %, RI 1 año
- R6** Sanción legal → SHAP + canal humano apelación
- R7** Fallo legacy → pruebas integración sprint 1
- R8** Rotación DS → documentación viva, pair prog

El proyecto es VIABLE bajo salvaguardas éticas y legales robustas.

Todas las cifras están respaldadas en el Anexo Técnico (Jupyter Notebook). Los perfiles de mayor gasto (fumadores obesos, mayores de 50) permiten ahorros sustanciales vía prevención focalizada, SIN tarificar primas individuales.

1. Alternativa A

AWS + Python open source
US\$ 54.000/año · ROI 11,1×

2. Piloto 6 meses

Reportes agregados
NO decisiones individuales

3. Comité independiente

Métricas equidad, ROI real
y cumplimiento normativo

Anexo técnico: Anexo_Analisis_Caso2.ipynb — reproducible con Kernel > Restart & Run All